ESCUELA POLITÉCNICA NACIONAL

Facultad de Ingeniería de Sistemas

Carrera de Ciencia de Datos e Inteligencia Artificial

INFORME DE LABORATORIO · SEMANA 3

Clasificación de variables y población vs. muestra

IDSD422 — Estadística y Programación para Ciencia de Datos I

Caso de estudio: RetailAndina S.A.

Dato	Información
Estudiante	Tabatha Peñaloza · GitHub: Tabatha-Orellana
Docente	Christian Suarez
Período académico	2026-B
Fecha de elaboración	23/10/2026
Repositorio (fork)	https://github.com/Tabatha-Orellana/IDSD422-lab-muestreo-poblacion

Informe elaborado con los datos de clientes.csv y clientes_400.csv y evidencias originales de ejecución en Visual Studio Code.

Resumen ejecutivo

Clasifiqué las variables de fidelización de RetailAndina S.A. en Python y R y comparé tres diseños de muestreo para estimar el ingreso mensual promedio de 400 clientes. La media poblacional fue 1.330,725 USD. Las muestras de 20 clientes produjeron resultados distintos y la selección por conveniencia excluyó dos ciudades. Concluí que la representatividad depende del diseño y no solamente del tamaño de la muestra.

1. Introducción

RetailAndina S.A. necesitaba identificar los tipos de variables de su base de fidelización y evaluar si una muestra de 20 registros permite estimar el ingreso mensual medio de sus clientes. Analicé un extracto de 12 registros y una población de 400 clientes. Una clasificación inadecuada puede provocar interpretaciones estadísticas erróneas, mientras que una selección sesgada puede omitir subgrupos relevantes (Bruce et al., 2020).

2. Objetivos

General. Clasificar las variables de la base de fidelización y comparar tres diseños de muestreo frente al parámetro poblacional.

1. Identificar y justificar el tipo estadístico de siete variables y el identificador.
2. Verificar tipos inferidos, valores únicos y orden de las variables ordinales en Python y R.
3. Calcular la media poblacional y las estimaciones mediante tres muestras de tamaño 20.
4. Interpretar el sesgo de selección, la variabilidad entre semillas y sus implicaciones para gerencia.

3. Desarrollo de la práctica

3.1. Parte A — Clasificación de variables

Leí data/clientes.csv (12 filas y 8 columnas) con pandas y R. Consulté dtypes/str(), valores únicos y categorías. Definí nivel_educacion y satisfaccion como ordinales con CategoricalDtype y factor ordenado. Los procedimientos se documentan en las Figuras 1–5 y 8–10.

Código clave (Python): clientes = pd.read_csv("data/clientes.csv"); pd.CategoricalDtype(categories=[1,2,3,4,5], ordered=True). En R: factor(clientes$satisfaccion, levels=1:5, ordered=TRUE).

3.1. Parte A — Clasificación de variables (verificación)

Variable	Tipo	Justificación	Verificación
cliente_id	Nominal: identificador	Código sin cantidad ni orden	Texto; 12 únicos
edad	Numérica discreta*	Años completos registrados	Entero; 12 únicos
numero_hijos	Numérica discreta	Conteo de hijos	Entero; 5 únicos
genero	Nominal (3 clases)	Categorías sin orden	Texto; 3 únicos
nivel_educacion	Categórica ordinal	Primaria → Secundaria → Universidad → Posgrado	Texto → ordenada; 4 únicos
ciudad	Categórica nominal	Ciudades sin jerarquía	Texto; 3 únicos
ingresos_mensuales	Numérica continua	Monto monetario medible con decimales	Entero en CSV; 12 únicos
satisfaccion	Categórica ordinal	Grados ordenados (1–5)	Entero; 4 únicos observados

*La edad medida con mayor precisión puede tratarse como continua; aquí se registró en años enteros.

Al declarar las categorías, el nivel mínimo de educación fue Primaria. En satisfacción observé niveles de 2 a 5, aunque el orden admitido fue 1–5. En una prueba con “Postgrado” en vez de “Posgrado”, dos registros quedaron como valores faltantes, evidenciando que las etiquetas deben coincidir exactamente.

Pregunta P1

El dtype de satisfaccion fue entero (int64 en Python, int en R), pero ese tipo representa cómo se almacena y no su naturaleza estadística. Los valores expresan categorías con orden: satisfacción es ordinal. Si no declaro el orden, un programa puede aplicar una ordenación alfabética o comparar niveles incorrectamente. Por eso utilicé CategoricalDtype y factor ordenado y verifiqué la prueba del nivel mal escrito.

3.2. Parte B — Población vs. muestra

Trabajé con data/clientes_400.csv: Quito 200 clientes, Guayaquil 120 y Cuenca 80. La variable de interés fue ingresos_mensuales. Calculé la media poblacional completa como referencia para evaluar los diseños. Implementé Python con poblacion.head(20), poblacion.sample(n=20, random_state=1) y poblacion.groupby("ciudad").sample(frac=0.05, random_state=1).

Concepto	Valor
Población (N)	400 clientes
Variable de interés	ingresos_mensuales (USD)
Parámetro poblacional	1.330,725 USD
¿Por qué muestrear?	Para reducir costos y tiempo cuando no sea viable estudiar todos los clientes; aquí la media completa sirve de referencia.

Python — tres diseños, semilla 1:

Diseño	n	Media USD	Composición Quito / Guayaquil / Cuenca	Diferencia USD
Conveniencia	20	1.348,50	20 / 0 / 0	+17,775
Aleatorio simple	20	1.336,00	8 / 8 / 4	+5,275
Estratificado 5 %	20	1.287,50	10 / 6 / 4	−43,225

Medias de los cinco sorteos aleatorios simples de Python:

Semilla	1	2	3	4	5
Media USD	1.336,00	1.405,00	1.235,00	1.491,50	1.288,00

Contraste en R — semilla 1:

Diseño	Media USD	Quito / Guayaquil / Cuenca	Diferencia USD
Conveniencia	1.348,50	20 / 0 / 0	+17,775
Aleatorio simple	1.318,00	8 / 7 / 5	−12,725
Estratificado 5 %	1.226,00	10 / 6 / 4	−104,725

Semillas de R (1–5): 1.318,00; 1.287,50; 1.233,00; 1.385,50 y 1.283,00 USD. Python y R pueden seleccionar muestras diferentes aunque empleen la misma semilla. Véanse las Figuras 6 y 7.

3.3. Respuestas a las preguntas P2–P5

P2. Parámetro y estimación de cada diseño

El parámetro fue 1.330,725 USD. En Python, las medias estimadas fueron 1.348,50 USD (conveniencia), 1.336,00 USD (aleatorio simple) y 1.287,50 USD (estratificado). En esta ejecución, el aleatorio simple presentó el menor error absoluto: 5,275 USD. Eso no demuestra que sea superior en general; la cercanía de una sola muestra puede deberse al azar y debe evaluarse junto al sesgo y la variabilidad.

P3. Defecto de la selección por conveniencia

La muestra de 20 registros incluyó solo clientes de Quito porque la base estaba ordenada por ciudad. No representó a Guayaquil ni Cuenca. Aumentar n sin cambiar el mecanismo puede conservar la exclusión de subgrupos; por tanto, el problema no se corrige automáticamente tomando más filas.

P4. Variabilidad entre las cinco semillas

En Python, las medias oscilaron entre 1.235,00 y 1.491,50 USD. La variación ocurrió porque cada sorteo produjo una muestra diferente. Para una decisión empresarial, no basta un único resultado puntual: debería reportarse su incertidumbre, además de considerar el diseño de selección.

P5. Aplicación práctica de cada diseño

Usaría conveniencia en un piloto exploratorio sin pretender generalizar. Emplearía muestreo aleatorio simple cuando necesitara inferir sobre toda la población y contara con un marco de selección completo. Preferiría estratificación si fuera necesario garantizar la presencia de cada ciudad y analizar subgrupos, especialmente cuando su composición importa para el estudio.

Interpretación conjunta. El diseño por conveniencia evidenció una exclusión sistemática de ciudades (sesgo de selección); los resultados cambiantes entre semillas evidenciaron variabilidad muestral. Son problemas distintos. Ningún diseño debe elegirse solamente porque en una ejecución su estimación estuvo más cerca de la media real.

4. ¿Qué aprendí con esta práctica?

Aprendí que el tipo inferido por un lenguaje no siempre coincide con la clasificación estadística. Aunque satisfaccion se almacenaba como entero, interpreté sus valores como niveles ordinales. La prueba de Postgrado también me mostró que un nivel mal escrito puede convertirse en un valor faltante. En la parte de muestreo comprobé que el tamaño 20 no garantiza representatividad: la muestra por conveniencia incluyó únicamente Quito, mientras que la estratificada mantuvo las proporciones de las tres ciudades.

Tuve dificultades al ejecutar R en VS Code porque PowerShell no reconocía Rscript y después faltaba el paquete dplyr. Configuré la ruta del intérprete, instalé la dependencia y volví a ejecutar el script hasta obtener resultados completos. La próxima vez revisaré el entorno y las dependencias antes de programar y organizaré las evidencias desde el inicio.

5. Conclusiones

1. Clasifiqué las siete variables y el identificador de doce clientes. Verifiqué que satisfaccion es ordinal, aunque su dtype era numérico, y que un error en Posgrado produjo dos faltantes.

2. La población de 400 clientes presentó una media de 1.330,725 USD. En la muestra por conveniencia de 20 clientes, Quito concentró el 100 %, excluyendo las otras dos ciudades.

3. Las estimaciones cambiaron según diseño, lenguaje y semilla. Recomendaría a gerencia elegir una muestra probabilística adecuada a los subgrupos y reportar la incertidumbre; el diseño importa más que el tamaño aislado.

6. Bibliografía

Bruce, P., Bruce, A., & Gedeck, P. (2020). Practical Statistics for Data Scientists (2.ª ed.). O'Reilly Media.

pandas development team. (s. f.). pandas.CategoricalDtype. https://pandas.pydata.org/docs/reference/api/pandas.CategoricalDtype.html

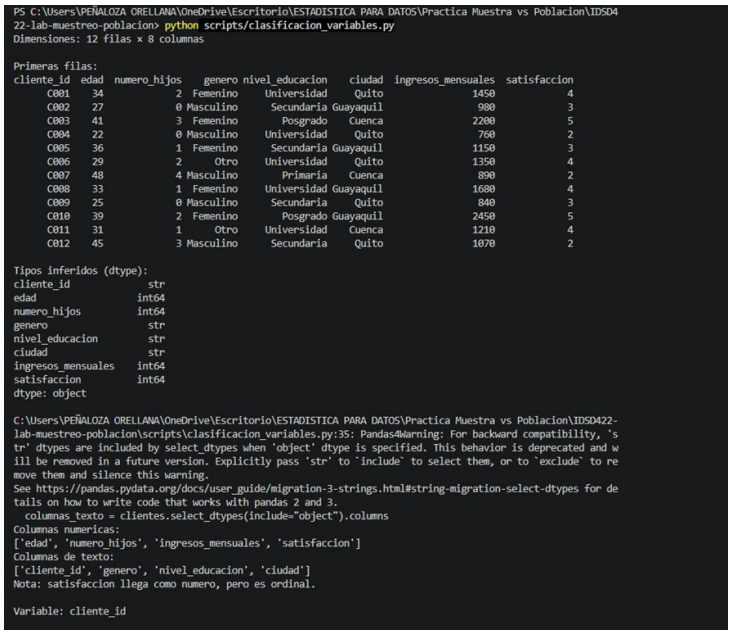
pandas development team. (s. f.). DataFrame.sample. https://pandas.pydata.org/docs/reference/api/pandas.DataFrame.sample.html

Wickham, H., François, R., Henry, L., Müller, K., & Vaughan, D. (s. f.). dplyr: A grammar of data manipulation. https://dplyr.tidyverse.org/

Escuela Politécnica Nacional. (2026). Datos didácticos: clientes.csv y clientes_400.csv [Repositorio del laboratorio].

Declaración de uso de IA. Utilicé ChatGPT como apoyo para comprender instrucciones, orientar la corrección de errores técnicos y organizar la redacción. Ejecuté los scripts en VS Code y contrasté las cifras con las salidas y capturas propias.

7. Anexos — Evidencias de ejecución



```
PS C:\Users\PEÑALOZA ORELLANA\OneDrive\Escritorio\ESTADISTICA PARA DATOS\Practica Muestra vs Poblacion\IDSD4
22-lab-muestreo-poblacion> python scripts/clasificacion_variables.py
Dimensiones: 12 filas x 8 columnas

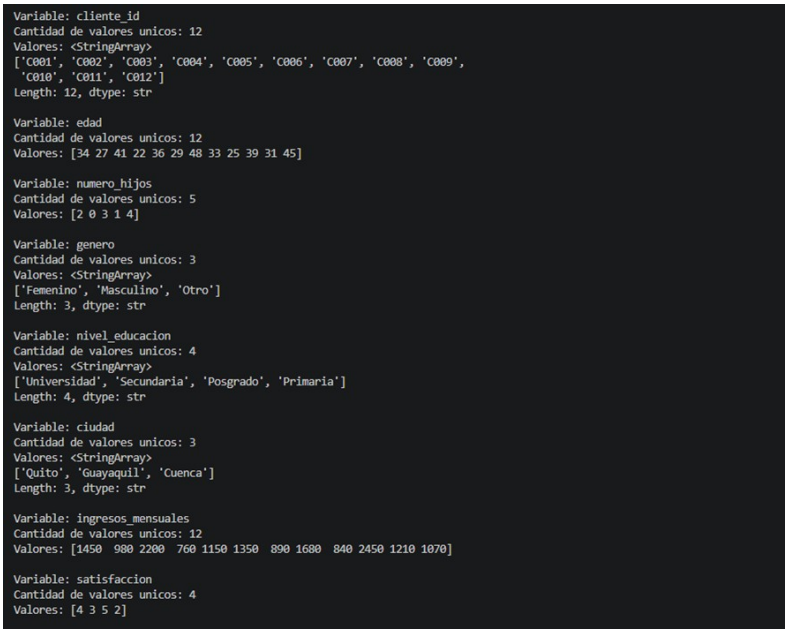
Primeras filas:
cliente_id  edad  numero_hijos    genero nivel_educacion    ciudad  ingresos_mensuales  satisfaccion
      C001    34             2  Femenino     Universidad     Quito                1450             4
      C002    27             0 Masculino      Secundaria Guayaquil                 980             3
      C003    41             3  Femenino        Posgrado    Cuenca                2200             5
      C004    22             0 Masculino     Universidad     Quito                 760             2
      C005    36             1  Femenino      Secundaria Guayaquil                1150             3
      C006    29             2      Otro     Universidad     Quito                1350             4
      C007    48             4 Masculino        Primaria    Cuenca                 890             2
      C008    33             1  Femenino     Universidad Guayaquil                1680             4
      C009    25             0 Masculino      Secundaria     Quito                 840             3
      C010    39             2  Femenino        Posgrado Guayaquil                2450             5
      C011    31             1      Otro     Universidad    Cuenca                1210             4
      C012    45             3 Masculino      Secundaria     Quito                1070             2

Tipos inferidos (dtype):
cliente_id            str
edad                int64
numero_hijos        int64
genero                str
nivel_educacion       str
ciudad                str
ingresos_mensuales  int64
satisfaccion        int64
dtype: object

C:\Users\PEÑALOZA ORELLANA\OneDrive\Escritorio\ESTADISTICA PARA DATOS\Practica Muestra vs Poblacion\IDSD422-
lab-muestreo-poblacion\scripts\clasificacion_variables.py:35: Pandas4Warning: For backward compatibility, 's
tr' dtypes are included by select_dtypes when 'object' dtype is specified. This behavior is deprecated and w
ill be removed in a future version. Explicitly pass 'str' to `include` to select them, or to `exclude` to re
move them and silence this warning.
See https://pandas.pydata.org/docs/user_guide/migration-3-strings.html#string-migration-select-dtypes for de
tails on how to write code that works with pandas 2 and 3.
  columnas_texto = clientes.select_dtypes(include="object").columns
Columnas numericas:
['edad', 'numero_hijos', 'ingresos_mensuales', 'satisfaccion']
Columnas de texto:
['cliente_id', 'genero', 'nivel_educacion', 'ciudad']
Nota: satisfaccion llega como numero, pero es ordinal.

Variable: cliente_id
```

Figura 1. Python: dimensiones, registros y tipos inferidos de clientes.csv.



```
Variable: cliente_id
Cantidad de valores unicos: 12
Valores: <StringArray>
['C001', 'C002', 'C003', 'C004', 'C005', 'C006', 'C007', 'C008', 'C009',
 'C010', 'C011', 'C012']
Length: 12, dtype: str

Variable: edad
Cantidad de valores unicos: 12
Valores: [34 27 41 22 36 29 48 33 25 39 31 45]

Variable: numero_hijos
Cantidad de valores unicos: 5
Valores: [2 0 3 1 4]

Variable: genero
Cantidad de valores unicos: 3
Valores: <StringArray>
['Femenino', 'Masculino', 'Otro']
Length: 3, dtype: str

Variable: nivel_educacion
Cantidad de valores unicos: 4
Valores: <StringArray>
['Universidad', 'Secundaria', 'Posgrado', 'Primaria']
Length: 4, dtype: str

Variable: ciudad
Cantidad de valores unicos: 3
Valores: <StringArray>
['Quito', 'Guayaquil', 'Cuenca']
Length: 3, dtype: str

Variable: ingresos_mensuales
Cantidad de valores unicos: 12
Valores: [1450  980 2200  760 1150 1350  890 1680  840 2450 1210 1070]

Variable: satisfaccion
Cantidad de valores unicos: 4
Valores: [4 3 5 2]
```

Figura 2. Python: valores únicos de las variables de fidelización.

7. Anexos — Evidencias de ejecución

```
PS C:\Users\PEÑALOZA ORELLANA\OneDrive\Escritorio\ESTADISTICA PARA DATOS\Practica Muestra vs Poblacion\IDSD422-lab-muestreo-poblacion> $env:Pat
h += ";C:\Program Files\R\R-4.6.1\bin"
PS C:\Users\PEÑALOZA ORELLANA\OneDrive\Escritorio\ESTADISTICA PARA DATOS\Practica Muestra vs Poblacion\IDSD422-lab-muestreo-poblacion> Rscript
scripts/clasificacion_variables.R
Dimensiones: 12 filas × 8 columnas
   cliente_id edad numero_hijos    genero nivel_educacion    ciudad
1        C001   34           2  Femenino     Universidad     Quito
2        C002   27           0 Masculino      Secundaria Guayaquil
3        C003   41           3  Femenino        Posgrado    Cuenca
4        C004   22           0 Masculino     Universidad     Quito
5        C005   36           1  Femenino      Secundaria Guayaquil
6        C006   29           2      Otro     Universidad     Quito
7        C007   48           4 Masculino        Primaria    Cuenca
8        C008   33           1  Femenino     Universidad Guayaquil
9        C009   25           0 Masculino      Secundaria     Quito
10       C010   39           2  Femenino        Posgrado Guayaquil
11       C011   31           1      Otro     Universidad    Cuenca
12       C012   45           3 Masculino      Secundaria     Quito
   ingresos_mensuales satisfaccion
1                1450           4
2                 980           3
3                2200           5
4                 760           2
5                1150           3
6                1350           4
7                 890           2
8                1680           4
9                 840           3
10               2450           5
11               1210           4
12               1070           2
'data.frame':   12 obs. of  8 variables:
 $ cliente_id       : chr  "C001" "C002" "C003" "C004" ...
 $ edad             : int  34 27 41 22 36 29 48 33 25 39 ...
 $ numero_hijos     : int  2 0 3 0 1 2 4 1 0 2 ...
 $ genero           : chr  "Femenino" "Masculino" "Femenino" "Masculino" ...
 $ nivel_educacion  : chr  "Universidad" "Secundaria" "Posgrado" "Universidad" ...
 $ ciudad           : chr  "Quito" "Guayaquil" "Cuenca" "Quito" ...
 $ ingresos_mensuales: int  1450 980 2200 760 1150 1350 890 1680 840 2450 ...
 $ satisfaccion     : int  4 3 5 2 3 4 2 4 3 5 ...
```

Figura 3. R: inspección de las ocho columnas mediante str().

```
Columnas numericas:
[1] "edad"              "numero_hijos"      "ingresos_mensuales"
[4] "satisfaccion"

Columnas de texto:
[1] "cliente_id"     "genero"         "nivel_educacion" "ciudad"

Nota: satisfaccion llega como numero, pero es ordinal.

Variable: cliente_id
Cantidad de valores unicos: 12
 [1] "C001" "C002" "C003" "C004" "C005" "C006" "C007" "C008" "C009" "C010"
[11] "C011" "C012"

Variable: edad
Cantidad de valores unicos: 12
 [1] 34 27 41 22 36 29 48 33 25 39 31 45

Variable: numero_hijos
Cantidad de valores unicos: 5
[1] 2 0 3 1 4

Variable: genero
Cantidad de valores unicos: 3
[1] "Femenino"  "Masculino" "Otro"

Variable: nivel_educacion
Cantidad de valores unicos: 4
[1] "Universidad" "Secundaria"  "Posgrado"    "Primaria"

Variable: ciudad
Cantidad de valores unicos: 3
[1] "Quito"     "Guayaquil" "Cuenca"

Variable: ingresos_mensuales
Cantidad de valores unicos: 12
 [1] 1450  980 2200  760 1150 1350  890 1680  840 2450 1210 1070

Variable: satisfaccion
Cantidad de valores unicos: 4
```

Figura 4. R: verificación de valores únicos y categorías.

7. Anexos — Evidencias de ejecución

```
Nivel de educacion ordenado:
[1] "Primaria"    "Secundaria"  "Universidad" "Posgrado"

Nivel minimo de educacion:
[1] Primaria
Levels: Primaria < Secundaria < Universidad < Posgrado

Satisfaccion ordenada:
[1] "1" "2" "3" "4" "5"

¿Satisfaccion es ordinal?
[1] TRUE

Prueba con 'Postgrado' mal escrito:
Cantidad de valores faltantes:
[1] 2

Resumen de la clasificación (para el informe):
  cliente_id         Categorica nominal (identificador)
  edad               Numerica discreta (registrada en anos completos)
  numero_hijos       Numerica discreta
  genero             Categorica nominal
  nivel_educacion    Categorica ordinal
  ciudad             Categorica nominal
  ingresos_mensuales Numerica continua
  satisfaccion       Categorica ordinal
```

Figura 5. R: factores ordenados y prueba con la categoría Postgrado.

```
PS C:\Users\PEÑALOZA ORELLANA\OneDrive\Escritorio\ESTADISTICA PARA DATOS\Practica Muestra vs Poblacion\IDSD422-lab-muestreo-poblacion> python s
cripts/muestreo.py
Población: 400 clientes × 8 columnas
Parámetro poblacional — ingreso medio: 1330.72 USD
Ciudades en la población: {'Quito': 200, 'Guayaquil': 120, 'Cuenca': 80}

--- MEDIAS DE 5 SORTEOS ALEATORIOS ---
Semilla 1: 1336.00 USD
Semilla 2: 1405.00 USD
Semilla 3: 1235.00 USD
Semilla 4: 1491.50 USD
Semilla 5: 1288.00 USD

[Conveniencia] n=20  media=1348.50 USD  (parámetro 1330.72, diferencia +17.78)
    composición por ciudad: {'Quito': 20}
[Aleatorio simple] n=20  media=1336.00 USD  (parámetro 1330.72, diferencia +5.28)
    composición por ciudad: {'Cuenca': 8, 'Quito': 8, 'Guayaquil': 4}
[Estratificado] n=20  media=1287.50 USD  (parámetro 1330.72, diferencia -43.22)
    composición por ciudad: {'Quito': 10, 'Guayaquil': 6, 'Cuenca': 4}

Parámetro poblacional: 1330.72 USD
                      diseño  n  media estimada
          Conveniencia (head) 20         1348.5
     Aleatorio simple (sample) 20         1336.0
Estratificado (groupby + frac) 20         1287.5

Con estas salidas responde las preguntas P2 a P5:
P2: Comparación de medias contra el parámetro.
P3: Sesgo de selección por conveniencia.
P4: Variabilidad entre semillas.
P5: Aplicaciones de cada diseño.
```

Figura 6. Python: media poblacional, cinco semillas y tres diseños de muestreo.

7. Anexos — Evidencias de ejecución

```
PS C:\Users\PEÑALOZA ORELLANA\OneDrive\Escritorio\ESTADISTICA PARA DATOS\Practica Muestra vs Poblacion\IDSD422-lab-muestreo-poblacion> Rscript
scripts/muestreo.R
--- POBLACION ---
Clientes: 400
Columnas: 8
Media poblacional: 1330.72 USD

Composicion por ciudad:

   Cuenca Guayaquil     Quito
      80       120       200

--- MEDIAS DE CINCO SORTEOS ---
Semilla 1: 1318.00 USD
Semilla 2: 1287.50 USD
Semilla 3: 1233.00 USD
Semilla 4: 1385.50 USD
Semilla 5: 1283.00 USD

--- COMPARACION DE DISEÑOS ---
[Conveniencia] n=20  media=1348.50 USD  (parametro 1330.72, diferencia +17.78)

Quito
   20

[Aleatorio simple] n=20  media=1318.00 USD  (parametro 1330.72, diferencia -12.72)

   Cuenca Guayaquil     Quito
         5         7         8

[Estratificado] n=20  media=1226.00 USD  (parametro 1330.72, diferencia -104.72)

   Cuenca Guayaquil     Quito
         4         6        10


--- TABLA RESUMEN ---
          diseno  n media_estimada diferencia
    Conveniencia 20         1348.5     17.775
 Aleatorio simple 20         1318.0    -12.725
   Estratificado 20         1226.0   -104.725

--- COMPOSICION DE LA MUESTRA ESTRATIFICADA ---

   Cuenca Guayaquil     Quito
         4         6        10
```

Figura 7. R: resultados completos de conveniencia, aleatorio simple y estratificado.

```
PS C:\Users\PEÑALOZA ORELLANA\OneDrive\Escritorio\ESTADISTICA PARA DATOS\Practica Muestra vs Poblacion\IDSD422-lab-muestreo-poblacion> python scripts/clasificacion_variables.py
Dimensiones: 12 filas × 8 columnas

Primeras filas:
cliente_id  edad  numero_hijos    genero nivel_educacion    ciudad  ingresos_mensuales  satisfaccion
      C001    34             2  Femenino     Universidad     Quito               1450             4
      C002    27             0 Masculino      Secundaria Guayaquil                980             3
      C003    41             3  Femenino       Posgrado    Cuenca               2200             5
      C004    22             0 Masculino     Universidad     Quito                760             2
      C005    36             1  Femenino      Secundaria Guayaquil               1150             3
      C006    29             2      Otro     Universidad     Quito               1350             4
      C007    48             4 Masculino        Primaria    Cuenca                890             2
      C008    33             1  Femenino     Universidad Guayaquil               1680             4
      C009    25             0 Masculino      Secundaria     Quito                840             3
      C010    39             2  Femenino       Posgrado Guayaquil               2450             5
      C011    31             1      Otro     Universidad    Cuenca               1210             4
      C012    45             3 Masculino      Secundaria     Quito               1070             2

Tipos inferidos (dtype):
cliente_id             str
edad                 int64
numero_hijos         int64
genero                 str
nivel_educacion        str
ciudad                 str
ingresos_mensuales   int64
satisfaccion         int64
dtype: object

C:\Users\PEÑALOZA ORELLANA\OneDrive\Escritorio\ESTADISTICA PARA DATOS\Practica Muestra vs Poblacion\IDSD422-lab-muestreo-poblacion\scripts\clasificacion_variables.py:35: Pandas4Warning: For backwa
rd compatibility, 'str' dtypes are included by select_dtypes when 'object' dtype is specified. This behavior is deprecated and will be removed in a future version. Explicitly pass 'str' to `includ
e` to select them, or to `exclude` to remove them and silence this warning.
See https://pandas.pydata.org/docs/user_guide/migration-3-strings.html#string-migration-select-dtypes for details on how to write code that works with pandas 2 and 3.
  columnas_texto = clientes.select_dtypes(include="object").columns
Columnas numericas:
['edad', 'numero_hijos', 'ingresos_mensuales', 'satisfaccion']
Columnas de texto:
['cliente_id', 'genero', 'nivel_educacion', 'ciudad']
Nota: satisfaccion llega como numero, pero es ordinal.

Variable: cliente_id
Cantidad de valores unicos: 12
Valores: <StringArray>
['C001', 'C002', 'C003', 'C004', 'C005', 'C006', 'C007', 'C008', 'C009',
 'C010', 'C011', 'C012']
Length: 12, dtype: str

Variable: edad
Cantidad de valores unicos: 12
Valores: [34 27 41 22 36 29 48 33 25 39 31 45]

Variable: numero_hijos
```

Figura 8. Python: comprobación adicional de datos y tipos inferidos.

7. Anexos — Evidencias de ejecución

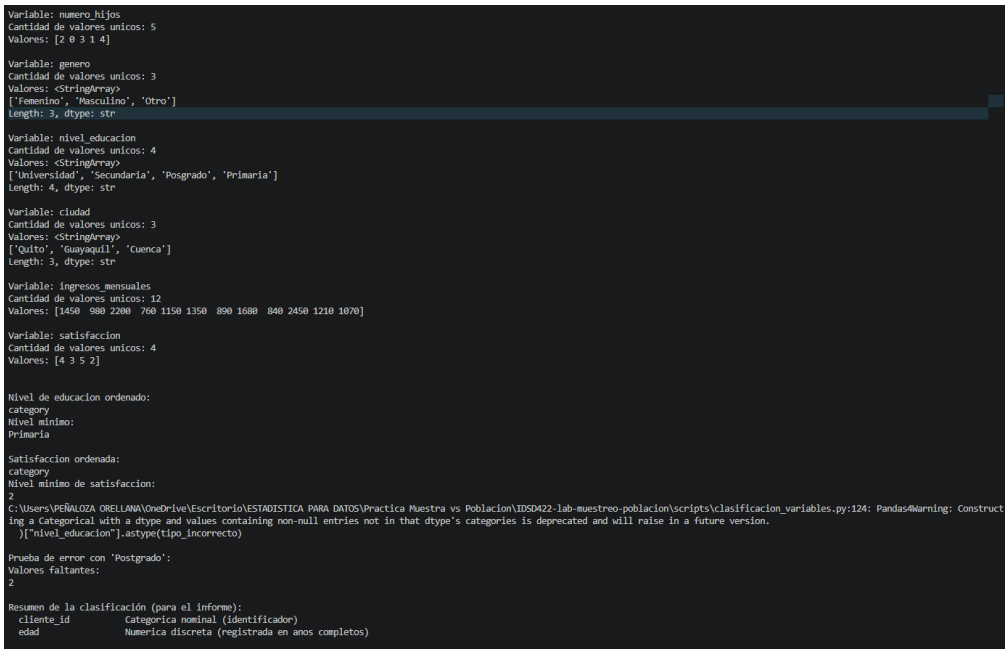


Figura 9. Python: ordinales y valores faltantes por categoría incorrecta.



Figura 10. Python: resumen de las ocho variables clasificadas.